

Dinâmica Guiada por Dados

Uma Introdução

Paolo F. Ferrari

Laboratório de Mecânica Offshore
Universidade de São Paulo

16 de Agosto de 2024



Ordem de apresentação

- 1 Critérios de seleção de modelos
- 2 Quantificação de incertezas
- 3 Redução da ordem de modelos

Critérios de seleção de modelos

Podemos dividir o processo em três etapas:

Definição de modelos admissíveis: Em geral, se baseia no conhecimento do modelo físico real.

Deteccção/Estimação de parâmetros: Otimização de uma métrica a partir dos parâmetros livres do modelo.

Quantificação de incertezas: Usando conhecimento prévio ou uma base de dados, calcular o nível de confiança sobre o valor dos parâmetros estimados.

Critérios de seleção de modelos

Muitos sistemas físicos são governados por equações do tipo

$$Y = f_0(X, \epsilon)$$

Onde X são as variáveis de controle, Y são as variáveis de resposta e ϵ representa o ruído ou o conjunto de variáveis incontroláveis no sistema.

Um modelo do sistema tem a forma

$$Y = f(X; \theta)$$

Onde θ são as variáveis que parametrizam a função-modelo f . Em dinâmica, os modelos são geralmente do tipo

Sistemas Contínuo	Sistema Discreto
$Y = \frac{dX}{dt} = f(X; \theta)$	$Y = X_{t+1} = f(X_t; \theta)$

► Como achar o modelo f e os parâmetros θ ?

Critérios de seleção de modelos

O objetivo de todo modelo é o de ser o mais próximo possível do sistema real, isto é, o resíduo $R(\theta) = Y - f(X; \theta)$ deve ser o menor possível para dados reais (X, Y) amostrados a partir da distribuição $p(X, Y)$.

Dois números descrevem a qualidade de um modelo com parâmetros $\hat{\theta}$ estimados a partir de dados: viés e variância.

Viés (bias):

$$\text{Bias}(\hat{\theta}) = \mathbb{E}[R(\hat{\theta})]$$

Variância:


$$\text{Var}(\hat{\theta}) = \mathbb{E}[(R(\hat{\theta}) - \text{Bias}(\hat{\theta}))^2]$$

De forma que:

$$\mathbb{E}[R(\hat{\theta})]^2 = \text{Bias}(\hat{\theta})^2 + \text{Var}(\hat{\theta})^2$$

De maneira geral, modelos de baixa complexidade possuem viés grande enquanto modelos de alta complexidade possuem variância grande.

Critérios de seleção de modelos



Critérios de seleção de modelos

- ▶ Os melhores valores para os parâmetros $\hat{\theta}$ são os que minimizam o resíduo $R(\theta)$
- ▶ Porém, na prática, não sabemos a função de distribuição real $p(X, Y)$, por isso é impossível saber $R(\theta)$
- ▶ O melhor que podemos fazer é amostrar um conjunto de dados $\mathcal{D} = \{(X_i, Y_i)\}_{i=1}^N$ e assumir que $\mathcal{D}$ represente $p(X, Y)$ de maneira razoável (melhor quanto maior N)
- ▶ Podemos então aproximar o resíduo exato R por um funcional F que depende de $\mathcal{D}$: $R(\theta) \approx F_{\mathcal{D}}(\theta)$
- ▶ A escolha mais comum para F é a soma dos quadrados dos resíduos individuais

$$F_{\mathcal{D}}(\theta) = \|Y - f(X; \theta)\|^2 = \sum_{i=1}^N (Y_i - f(X_i; \theta))^2$$

Em que

$$\hat{\theta} = \underset{\theta \in \Theta}{\operatorname{argmin}} F_{\mathcal{D}}(\theta)$$

Onde Θ é o conjunto de valores admissíveis para θ .

Cr terios de sele  o de modelos

No entanto, os dados podem ter muito ru do ou a pr pria fun  o-modelo $f(X; \theta)$ pode n o ter a forma f sica correta.

Por isso, de maneira geral, recomenda-se:

1. Dividir os dados entre dados de treino e teste
2. Usar uma outra forma para a fun  o objetivo $F_{\mathcal{D}}(\theta)$

M�todo	$F_{\mathcal{D}}(\theta)$
M�nimos quadrados	$\ Y - f(X; \theta)\ ^2$
Regress�o lasso	$\ Y - f(X; \theta)\ ^2 + \lambda \ \theta\ _1$
Regress�o ridge	$\ Y - f(X; \theta)\ ^2 + \lambda \ \theta\ _2^2$
Regress�o el�stica	$\ Y - f(X; \theta)\ ^2 + \lambda_1 \ \theta\ _1 + \lambda_2 \ \theta\ _2^2$
AIC/GIC	$\ Y - f(X; \theta)\ ^2 + \ \theta\ _0$
BIC	$\ Y - f(X; \theta)\ ^2 + N \ \theta\ _0$

Critérios de seleção de modelos

Estes métodos podem ser obtidos a partir de uma função de **verossimilhança** $p(\mathcal{D}|\theta)$ (probabilidade de observação dos dados).

- ▶ Máxima verossimilhança:

$$\hat{\theta} = \operatorname{argmax}_{\theta \in \Theta} \log(p(\mathcal{D}|\theta))$$

- ▶ Máxima probabilidade a posteriori:

$$\hat{\theta} = \operatorname{argmax}_{\theta \in \Theta} \log(p(\theta|\mathcal{D})) = \operatorname{argmax}_{\theta \in \Theta} [\log(p(\mathcal{D}|\theta)) + \log(p(\theta))]$$

- ▶ Critérios de informação:

$$\hat{\theta} = \operatorname{argmax}_{\theta \in \Theta} [p(\mathcal{D}|\theta) + f_I(\theta)]$$

Critérios de seleção de modelos

Como escolher entres esses critérios?

► Métodos com conhecimento prévio de θ :

MAP: A probabilidade a priori $p(\theta)$ pode ser estimada a partir de modelos já existentes, de experimentos anteriores, ou da literatura.

Algoritmo (Bayes): Dados uma probabilidade priori $p_0(\theta)$ e função verossimilhança $p(\mathcal{D}|\theta)$. Para cada novo conjunto de dados $\mathcal{D}_n$, atualize a probabilidade conforme

$$p_n(\theta) \leftarrow p(\theta|\mathcal{D}_n) = \frac{p(\mathcal{D}_n|\theta)p_{n-1}(\theta)}{p(\mathcal{D}_n)}$$

Ao final, $\hat{\theta} \leftarrow \operatorname{argmax}_{\theta \in \Theta} p_N(\theta)$.

► Métodos sem o conhecimento prévio de θ


MLE (mínimos quadrados): simples, mas corre-se o risco de overfitting

Critérios de informação: útil para comparar modelos com número diferentes de parâmetros, menor risco de overfitting

Validação cruzada: útil em situações sem conhecimento prévio mas com base de dados grande

Validação cruzada

- ▶ Divida os dados em N fatias, treinando o modelo em $N - 1$ fatias e calculando o erro na fatia de teste. Repita N vezes e escolha os parâmetros com menor erro médio.



Fonte: scikit-learn


Uma vez identificado os parâmetros $\hat{\theta}$, como saber se os valores são confiáveis?
Resposta: calculando a probabilidade a posteriori $p(\hat{\theta}|\mathcal{D})$.

Ao invés de valores únicos, é desejado obter o **intervalo de confiança** de $\hat{\theta}$, isto é, os valores de θ^- e θ^+ tais que $\hat{\theta} \in [\theta^-, \theta^+]$ e $p(\theta^- < \theta < \theta^+|\mathcal{D}) = P$ ($P = 0.95$ na maioria dos casos).

- Métodos exatos: ótimo para modelos simples, como regressão linear $Y = X\beta + \epsilon$. Permite calcular $p(\hat{\beta}|\mathcal{D})$ de maneira direta.
- Simulações de Monte-Carlo: permite estimar $p(\theta|\mathcal{D})$ por amostragens já que $p(\theta|\mathcal{D}) \propto p(\mathcal{D}|\theta)p(\theta)$
- Métodos de Ensembling: método robusto e de fácil implementação

Quantificação de incertezas

Exemplo: Modelo SINDy



Fonte: U. Fasel et al (2022)

Redução de ordem de modelos

Para $X \in \mathbb{R}^n$,

$$\dot{X} = F(X) = DF|_0 X + N_F(X)$$

Onde $F(0) = 0$, $DF|_0$ é a parte linear de F perto da origem e N_F a parte não-linear. Buscamos uma forma reduzida do sistema através de um mapeamento $X = W(z)$ tal que $z \in \mathbb{R}^d$ ($d < n$) e a dinâmica em z é dada por

$$\dot{z} = f(z) = Df|_0 z + N_f(z)$$

Onde $f(0) = 0$. A condição de invariância é

$$DWf(z) = F(W(z))$$

Onde DW é a derivada (Jacobiano) do mapa W .

- ▶ A equação invariante descreve uma variedade (manifold) invariante de dimensão d no espaço original de dimensão n

Redução da ordem de modelos


Exemplo: Modos normais não-lineares

Um sistema mecânico obtido a partir de elementos finitos tem a forma

$$M\ddot{x} + C\dot{x} + Kx + N(x, \dot{x}) = 0$$

Com $x \in \mathbb{R}^n$. Tomando $X = (x, \dot{x})$, o sistema toma a forma

$$\dot{X} = \begin{bmatrix} 0 & Id \\ -M^{-1}K & -M^{-1}C \end{bmatrix} X + \begin{bmatrix} 0 \\ -M^{-1}N(X) \end{bmatrix}$$



Fonte: S. Ponsioen et al. (2018)

Redução da ordem de modelos

No método de parametrização direta, o mapa W é polinomial em z . A expansão de ordem $N - 1$ de W é

$$W_{<N}(z) = \sum_{k=1}^{N-1} W_k(z) = \sum_{k=1}^{N-1} \sum_{|\alpha|=k} W_{\alpha_1, \alpha_2, \dots, \alpha_d} z_1^{\alpha_1} z_2^{\alpha_2} \dots z_d^{\alpha_d}$$

Da mesma forma, o fluxo f é

$$f_{<N}(z) = \sum_{k=1}^{N-1} f_k(z) = \sum_{k=1}^{N-1} \sum_{|\alpha|=k} f_{\alpha_1, \alpha_2, \dots, \alpha_d} z_1^{\alpha_1} z_2^{\alpha_2} \dots z_d^{\alpha_d}$$

O objetivo do método é achar aproximações sucessivas para a equação de invariância

$$DWf(z) = F(W(z))$$

Redução da ordem de modelos

Para isso, supõe-se que, na aproximação de ordem $k - 1$ da equação, o resíduo possui apenas termos de ordem k ou superior:

$$DW_{<k}f_{<k}(z) - F(W_{<k}(z)) = R_k + O_{k+1}$$

Onde R_k tem ordem k . Esse resíduo é então eliminado na próxima aproximação de ordem k :

$$D(W_{<k}(z) + W_k)(f_{<k}(z) + f_k(z)) - F(W_{<k}(z) + W_k) = 0$$

Expandindo a equação e coletando os termos de ordem k , obtêm-se a equação homológica de ordem k :

$$DW_k Df|_0 z + Lf^k(z) - DF|_0 W_k(z) = [F(W_{<k}(z))]_k - [DW_{<k}(z)f_{<k}(z)]_k = R_k(z)$$

Onde $L = DW|_{z=0}$.

Redução da ordem de modelos

A equação homológica de ordem k do sistema

$$DW_k Df|_0 z + Lf^k(z) - DF|_0 W_k(z) = [F(W_{<k}(z))]_k - [DW_{<k}(z)f_{<k}(z)]_k = R_k(z)$$

Supondo que as matrizes $DF|_0$ e $Df|_0$ estejam sob sua forma diagonal, é possível reescrever a equação conforme

$$\Lambda \xi_k(z) - D\xi_k(z)\Lambda_L z - \begin{bmatrix} Id \\ 0 \end{bmatrix} f_k(z) = \eta_k(z)$$

Onde $\xi_k(z)$ representa $W_k(z)$ e $\eta_k(z)$ representa $R_k(z)$ sob um outro sistema de coordenadas. Essa equação pode ser escrita em termos dos componentes dos polinômios que são tangente e normais à variedade invariante:

$$(\lambda_i - \lambda_L m)\xi_m^i - f_m^i = \eta_m^i$$

$$(\lambda_i - \lambda_L m)\xi_m^i = \eta_m^i$$

Essas equações podem ser facilmente resolvidas para os coeficientes ξ_m^i e f_m^i uma vez que η_m^i são conhecidos.

Redução da ordem de modelos

O trabalho computacional pesado do algoritmo está no cálculo de composição das séries

$$E_k(z) = [F(W_{<k}(z))]_k - [DW_{<k}(z)f_{<k}(z)]_k$$

O problema é calcular os coeficientes do polinômio resultante de uma composição de funções $f(g(z))$.

Para isso, podemos usar o fato que os coeficientes são dados por derivadas de alta ordem. Essas derivadas podem ser calculadas iterativamente, através da técnica de diferenciação automática.

Redução da ordem de modelos

Table 2.1 Some elementary functions of power series.

elementary function	$k \geq 1$	C
$p(x) = af(x) \pm bg(x)$	$p_k(x) = af_k(x) \pm bg_k(x)$	0
$p(x) = f(x)g(x)$	$p_k(x) = \sum_{j=0}^k f_j(x)g_{k-j}(x)$	1
$d(x) = f(x)/g(x)$	$d_k(x) = \frac{1}{g_0} \left(f_k(x) - \sum_{j=0}^{k-1} d_j(x)g_{k-j}(x) \right)$	1
$p(x) = (f(x))^a$	$p_k(x) = \frac{1}{k} \sum_{j=0}^{k-1} (\alpha(k-j) - j) f_{k-j}(x) p_j(x)$	1
$p(x) = (f(x))^2$	$p_k(x) = \begin{cases} 2 \sum_{j=0}^{(k-1)/2} f_j(x)f_{k-j}(x), & \text{if } k \text{ odd} \\ 2 \sum_{j=0}^{(k-2)/2} f_j(x)f_{k-j}(x) + (f_{k/2}(x))^2, & \text{if } k \text{ even} \end{cases}$	0.5
$p(x) = (f(x))^{\frac{1}{2}}$	$p_k(x) = \begin{cases} \frac{1}{2p_0} \left(f_k(x) - 2 \sum_{j=1}^{(k-1)/2} p_j(x)p_{k-j}(x) \right), & \text{if } k \text{ odd} \\ \frac{1}{2p_0} \left(f_k(x) - 2 \sum_{j=1}^{(k-2)/2} p_j(x)p_{k-j}(x) - (p_{k/2}(x))^2 \right), & \text{if } k \text{ even} \end{cases}$	0.5
$e(x) = \exp(f(x))$	$e_k(x) = \frac{1}{k} \sum_{j=0}^{k-1} (k-j)f_{k-j}(x)e_j(x)$	1
$l(x) = \log(f(x))$	$l_k(x) = \frac{1}{f_0} \left(f_k(x) - \frac{1}{k} \sum_{j=1}^{k-1} j f_{k-j}(x) l_j(x) \right)$	1
$s(x) = \sin(f(x))$	$s_k(x) = \frac{1}{k} \sum_{j=0}^{k-1} (k-j)f_{k-j}(x)c_j(x)$	2
$c(x) = \cos(f(x))$	$c_k(x) = -\frac{1}{k} \sum_{j=0}^{k-1} (k-j)f_{k-j}(x)s_j(x)$	


Fonte: The Parametrization Method for Invariant Manifolds - Haro et al (2021).

Redução da ordem de modelos

Exemplo:

$$\begin{cases} E^{(1)}(x_1, x_2) = 4 \cos(x_1 - x_2) x_2^2 \\ E^{(2)}(x_1, x_2) = 2x_1 - x_1 x_2 \end{cases}$$

Rede computacional:




Redução da ordem de modelos

Exemplo:


$$\begin{cases} E^{(1)}(x_1, x_2) = 4 \cos(x_1 - x_2) x_2^2 \\ E^{(2)}(x_1, x_2) = 2x_1 - x_1 x_2 \end{cases}$$

Para cada nó na rede, o algoritmo calcula a nova série de ordem k usando as séries de ordem $k - 1$ e as séries de ordem k dos nós anteriores.



Redução da ordem de modelos

Fluxo de cálculo do modelo reduzido



Obrigado pela atenção!

Referências

1. Brunton, Steven L., Joshua L. Proctor, and J. Nathan Kutz. Discovering governing equations from data by sparse identification of nonlinear dynamical systems. *Proceedings of the national academy of sciences* 113.15 (2016): 3932-3937.
2. Fasel, Urban, et al. Ensemble-SINDy: Robust sparse model discovery in the low-data, high-noise limit, with active learning and control. *Proceedings of the Royal Society A* 478.2260 (2022): 20210904.
3. Haller, George, and Sten Ponsioen. Nonlinear normal modes and spectral submanifolds: existence, uniqueness and use in model reduction. *Nonlinear dynamics* 86 (2016): 1493-1534.
4. Haro, Alex, et al. The parameterization method for invariant manifolds. *Applied mathematical sciences* 195 (2016).